



- 본 과제는 학회 정규 세션 「Linear Algebra」, 「Basic Statistics」 및 「Math for ML」 일부 내용을 다루며, 개념의 이해와 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 평가를 위한 것이 아니므로, 주어진 힌트를 적극 활용하시고 학회원 간 토론, Slack의 질의응답을 활용하여 해결해주시요. 단, 답안 표절은 금지합니다.
- 2/11 (수) 23시 59분까지 Github 에 PDF 파일 하나로 제출해주시요. Github에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 활용해주시요.

문제 1 선형대수 기초 (Linear Algebra Basic)

1. $Ax = b$ 의 동치 조건

$n \times n$ 정사각행렬 A 에 대하여 다음 조건들은 동치(equivalent)입니다.

- 행렬 A 는 가역적(invertible)이다.
- 임의의 $n \times 1$ 벡터 b 에 대하여 방정식 $Ax = b$ 는 유일한 해를 갖는다.
- 동차 방정식(Homogeneous equation) $Ax = 0$ 은 오직 자명한 해(trivial solution, $x = 0$)만을 갖는다.

1-1. 다음과 같은 삼변수 함수 $f(x, y, z)$ 가 주어져 있습니다.

$$f(x, y, z) = x^2 + y^2 + 1.5z^2 + xy + yz + zx$$

- (1) 이 함수의 헤시안 행렬(Hessian Matrix) A 를 구하고 PD(Positive Definite), PSD, ND, NSD 중 무엇인지 판별하시오.

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{pmatrix} \quad \Delta_1 = 2 > 0 \quad \therefore A \text{ is Positive Definite.}$$

- (2) 위에서 구한 행렬 A 의 역행렬 A^{-1} 을 계산하시오.

$$\left[\begin{array}{ccc|ccc} 2 & 1 & 1 & 1 & 0 & 0 \\ 1 & 2 & 1 & 0 & 1 & 0 \\ 1 & 1 & 3 & 0 & 0 & 1 \end{array} \right] \rightarrow \left[\begin{array}{ccc|ccc} 1 & 1 & 1 & 0 & 0 & 1 \\ 1 & 2 & 1 & 0 & 1 & 0 \\ 2 & 1 & 1 & 1 & 0 & 0 \end{array} \right] \rightarrow \left[\begin{array}{ccc|ccc} 1 & 0 & 0 & 1 & -1 & 1 \\ 0 & 1 & 0 & -1 & 1 & 0 \\ 0 & 0 & 1 & 1 & -1 & 1 \end{array} \right] \quad A^{-1} = \begin{pmatrix} 1/5 & -1/5 & -1/5 \\ -1/5 & 1/5 & -1/5 \\ 1/5 & -1/5 & 1/5 \end{pmatrix} = \frac{1}{5} \begin{pmatrix} 1 & -1 & -1 \\ -1 & 1 & -1 \\ 1 & -1 & 1 \end{pmatrix}$$

- (3) 만약 특정 상수 k 에 대해 함수의 항 xy 가 kxy 로 변하여 $\det(A) = 0$ 이 된다면, 조건 (b)는 여전히 성립하는가? 그 이유를 행렬식(determinant)과 관련지어 설명하시오.

$$\begin{aligned} & \text{항 } xy \rightarrow kxy \text{로 변경} \quad \begin{pmatrix} 2 & k & 1 \\ k & 2 & 1 \\ 1 & 1 & 3 \end{pmatrix} \rightarrow \det(A) = (2-k)(3k+1)+k-2 \\ & \quad \quad \quad = 2-3k^2+2k=0 \quad \therefore \det(A)=0 \text{이면 } A \text{는 non-invertible 행렬.} \\ & \quad \quad \quad 3k^2-2k-2=0 \quad \quad \quad \therefore Ax=b \text{는 유일해를 갖지 않는다.} \\ & \quad \quad \quad k=2 \text{ 또는 } k=-2/3 \end{aligned}$$

1-2. (Optional)

- (1) (a), (b), (c) 세 조건들이 동치임을 증명하시오.

$$\begin{array}{|l} \text{i) (a) } \rightarrow \text{(b)} : Ax=b \text{에 대해} \\ A^T Ax = A^T b \Rightarrow x = A^T b \\ \therefore \text{해가 존재하고 유일하다.} \\ \text{ii) (b) } \rightarrow \text{(c)} : Ax=b, b \text{는 임의의 벡터.} \\ Ax=0, x=0. \\ \text{trivial solution을 갖는다.} \\ \text{iii) (c) } \rightarrow \text{(a)} : Ax=0 \rightarrow x=0 \\ \ker(A)=0, \text{ Null vector가 없다.} \\ A \text{는 full rank} \Leftrightarrow \det(A) \neq 0 \Leftrightarrow \text{invertible.} \end{array}$$

- (2) 행렬 A 가 가역적이라고 가정할 때, 임의의 b 에 대하여 $Ax = b$ 를 만족하는 해 x 가 항상 존재함을 대수적으로 유도하여 증명하고 해당 증명의 의미를 서술하시오.

$$\begin{aligned} & A \text{가 invertible} \Rightarrow A^{-1} \text{가 존재.} \quad \rightarrow A \text{가 가역이라는 것은 } T(x)=Ax \text{가 역함수를 가지는 변환.} \\ & \text{임의의 } b \text{에 대해 } x = A^{-1}b. \quad \text{1행 벡터 } b \text{든, } x \text{가 반드시 존재한다 (onto)} \\ & Ax = A(A^{-1}b) = (AA^{-1})b = b \\ & \text{모든 } b \text{에 대해 } x = A^{-1}b \text{가 존재한다.} \\ & \therefore A \text{가 가역이면 임의의 } b \text{에 대해 } Ax=b \text{의 해가 항상 존재한다.} \end{aligned}$$

문제 2 특이값 분해 (SVD)

특이값 분해(SVD)는 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 1) 항상 대칭 행렬을 이루는 두 행렬 $B^T B, B B^T$ 를 계산하고, 이들의 고유값을 계산해 특이값 σ 와 고유 벡터를 통해 직교대각화하여 $B^T B = V D V^T, B B^T = U D U^T$ 를 구합니다.
- 2) 0이 아닌 특이값들을 내림차순으로 나열하여 Σ 를 구성하고, 이들을 모두 활용해 $A = U \Sigma V^T$ 를 구합니다.

다음 행렬 B 에 특이값 분해를 적용하였을 때 나오는 행렬 U, Σ, V^T 를 각각 구하시오.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\textcircled{1} B B^T = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$$

$$\begin{vmatrix} 2-\lambda & 0 \\ 0 & 1-\lambda \end{vmatrix} = (2-\lambda)(1-\lambda) = 0$$

$$\lambda = 2, 1$$

$$\text{i) } \lambda = 2 \quad \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} = 0 \quad \therefore \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$\text{ii) } \lambda = 1 \quad \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} = 0 \quad \therefore \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

$$\Rightarrow U = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad \sigma_1 = \sqrt{2} \quad \sigma_2 = 1$$

$$\Sigma = \begin{pmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$

$$\textcircled{2} B^T B = \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{vmatrix} 1-\lambda & 1 & 0 \\ 1 & 1-\lambda & 0 \\ 0 & 0 & 1-\lambda \end{vmatrix} = (1-\lambda)\{(1-\lambda)^2 - 1\}$$

$$= (1-\lambda)\lambda(\lambda-2)$$

$$\lambda = 2, 1, 0$$

$$\text{i) } \lambda = 2 \quad \begin{pmatrix} -1 & 1 & 0 \\ 1 & -1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} = 0$$

$$v_1 = v_2, \quad v_3 = 0 \quad \rightarrow \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \rightarrow \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$$

$$\text{ii) } \lambda = 1 \quad \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} = 0 \quad \therefore \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

$$\text{iii) } \lambda = 0 \quad \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} = 0 \quad \therefore \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}$$

$$\Rightarrow V = \begin{pmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \end{pmatrix} \quad V^T = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \end{pmatrix}$$

$$B = U \Sigma V^T$$

$$= \underbrace{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}_U \underbrace{\begin{pmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}}_\Sigma \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \end{pmatrix}}_{V^T}$$

문제 3 Convex Sets & Functions

3-1. Convex Set

1. 다음 집합들이 Convex set 인지 증명하시오.

$$\begin{aligned}
 C_1 &= \{(x, y) \in \mathbb{R}^2 \mid x+y \leq 1\} \\
 \text{임의의 } (x_1, y_1), (x_2, y_2) \in C_1, \lambda \in [0, 1] \\
 x_1 + y_1 &\leq 1, \quad x_2 + y_2 \leq 1 \\
 (\lambda x, \lambda y) &= (\lambda x_1 + (1-\lambda)x_2, \lambda y_1 + (1-\lambda)y_2) \\
 x+y &= \lambda(x_1+y_1) + (1-\lambda)(x_2+y_2) \leq \lambda \cdot 1 + (1-\lambda) \cdot 1 = 1 \\
 \therefore (\lambda x, \lambda y) &\in C_1. \text{ 모든 } \lambda \in [0, 1] \text{에 대해 } C_1 \text{은 Convex set.}
 \end{aligned}$$

$$\begin{aligned}
 C_2 &= \{x \in \mathbb{R}^n \mid \|x\|_1 \leq 1\} \\
 x_1, x_2 \in C_2, \lambda \in [0, 1] \\
 \|\lambda x_1 + (1-\lambda)x_2\|_1 &\leq \|\lambda x_1\|_1 + \|(1-\lambda)x_2\|_1 \\
 &= \lambda \|x_1\|_1 + (1-\lambda)\|x_2\|_1 \leq \lambda + (1-\lambda) = 1 \\
 \therefore \lambda x_1 + (1-\lambda)x_2 &\in C_2. \therefore C_2 \text{는 Convex set.}
 \end{aligned}$$

$$\begin{aligned}
 C_3 &= \{(x, y) \in \mathbb{R}^2 \mid y \geq e^x\} \\
 (x_1, y_1), (x_2, y_2) \in C_3, \lambda \in [0, 1], y_1 \geq e^{x_1}, y_2 \geq e^{x_2} \\
 x &= \lambda x_1 + (1-\lambda)x_2, \quad y = \lambda y_1 + (1-\lambda)y_2 \\
 y &= \lambda y_1 + (1-\lambda)y_2 \geq \lambda e^{x_1} + (1-\lambda)e^{x_2} \\
 e^x &\text{는 convex function 이므로,} \\
 e^x &= e^{\lambda x_1 + (1-\lambda)x_2} \leq \lambda e^{x_1} + (1-\lambda)e^{x_2} \\
 y &\geq \lambda e^{x_1} + (1-\lambda)e^{x_2} \geq e^x \\
 \therefore (x, y) &\in C_3. \therefore C_3 \text{는 Convex set.}
 \end{aligned}$$

2. 함수 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 가 convex function 일 때, f 의 epigraph 인 집합 S 가 convex set 임을 보이시오.

$$\begin{aligned}
 (x_1, t_1), (x_2, t_2) \in S \text{를 잡으면,} \\
 t_1 \geq f(x_1), \quad t_2 \geq f(x_2) \\
 \lambda \in [0, 1] \text{에 대해, } (x, y) = (\lambda x_1 + (1-\lambda)x_2, \lambda t_1 + (1-\lambda)t_2) \\
 f \text{는 convex function 이므로} \\
 f(x) = f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2) \leq \lambda t_1 + (1-\lambda)t_2 = y \\
 \therefore t \geq f(x) \text{ 이므로 } (x, y) \in S. \quad S \text{는 Convex set.}
 \end{aligned}$$

3-2. Convex Function

1. Convex 함수의 합성

$f: \mathbb{R}^d \rightarrow \mathbb{R}$ 가 실수 값을 갖는 함수라고 합시다.

(a) 함수 $f(x)$ 와 $g(x)$ 가 convex 일 때, $f(x) + g(x)$ 또한 convex 임을 보이시오.

$$\begin{aligned}
 (f+g)(\lambda x + (1-\lambda)y) &= f(\lambda x + (1-\lambda)y) + g(\lambda x + (1-\lambda)y) \\
 &\leq \lambda f(x) + (1-\lambda)f(y) + \lambda g(x) + (1-\lambda)g(y) = \lambda(f+g)(x) + (1-\lambda)(f+g)(y) \\
 \therefore f(x) + g(x) &\text{는 Convex.}
 \end{aligned}$$

(b) A 와 b 가 호환되는 크기의 행렬과 벡터라고 합시다. $f(x)$ 가 convex 라면 $f(Ax + b)$ 또한 convex 임을 보이시오. $h(x) = f(Ax + b)$ 라고 하자.

$$\begin{aligned}
 x_1, x_2, \lambda \in [0, 1] \\
 h(\lambda x_1 + (1-\lambda)x_2) &= f(A(\lambda x_1 + (1-\lambda)x_2) + b) \\
 &= f(\lambda(Ax_1 + b) + (1-\lambda)(Ax_2 + b)) \leq \lambda f(Ax_1 + b) + (1-\lambda)f(Ax_2 + b) = \lambda h(x_1) + (1-\lambda)h(x_2) \\
 \therefore h(x) &= f(Ax + b) \text{는 Convex.}
 \end{aligned}$$

2. Convex Optimization

또 다른 함수 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 를 고려해 봅시다.

$$f(x) = \|Ax - b\|^2.$$

오직 convex 함수의 정의만을 사용하여, $f(x)$ 가 $x \in \mathbb{R}^d$ 에서 convex 임을 보이시오.

$$\hookrightarrow f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2).$$

$$u = Ax_1 - b, \quad v = Ax_2 - b$$

$$\begin{aligned}
 f(\lambda x_1 + (1-\lambda)x_2) &= \|\lambda(Ax_1 - b) + (1-\lambda)(Ax_2 - b)\|^2 \\
 &= \|\lambda u + (1-\lambda)v\|^2 \\
 &= \|\lambda u + (1-\lambda)v\|^2
 \end{aligned}$$

$$\therefore f(\lambda x_1 + (1-\lambda)x_2) = \|\lambda u + (1-\lambda)v\|^2 \leq \lambda \|u\|^2 + (1-\lambda)\|v\|^2$$

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2)$$

$$f(x) = \|Ax - b\|^2 \text{는 convex.}$$

$$\|\lambda u + (1-\lambda)v\|^2 = \lambda^2 \|u\|^2 + (1-\lambda)^2 \|v\|^2 + 2\lambda(1-\lambda)u^T v$$

$$\|u - v\|^2 \geq 0, \quad \|u - v\|^2 = \|u\|^2 + \|v\|^2 - 2u^T v \geq 0 \Rightarrow 2u^T v \leq \|u\|^2 + \|v\|^2$$

$$\begin{aligned}
 \|\lambda u + (1-\lambda)v\|^2 &\leq \lambda^2 \|u\|^2 + (1-\lambda)^2 \|v\|^2 + \lambda(1-\lambda)(\|u\|^2 + \|v\|^2) \\
 &= (\lambda^2 + \lambda(1-\lambda))\|u\|^2 + ((1-\lambda)^2 + \lambda(1-\lambda))\|v\|^2 \\
 &= \lambda \|u\|^2 + (1-\lambda)\|v\|^2
 \end{aligned}$$

문제 4 정보이론 (Information Theory)

4-1. Entropy

확률분포 $p(x, y)$ 가 다음과 같이 주어졌다고 합시다.

$X \backslash Y$	0	1	
0	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{2}{3}$
1	0	$\frac{1}{3}$	$\frac{1}{3}$
	$\frac{1}{3}$	$\frac{2}{3}$	

다음 값들을 구하시오.

(a) $H(X), H(Y)$. $H(X) = -\sum_x p(x) \log_2 p(x) = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3}$
 $H(Y) = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{3}$


(b) $H(X | Y), H(Y | X)$. $Y=0 \rightarrow P(X=0|Y=0)=\frac{1}{2}, P(X=1|Y=0)=\frac{1}{2} \rightarrow H(X|Y=0)=1$
 $Y=1 \rightarrow P(X=0|Y=1)=0, P(X=1|Y=1)=1 \rightarrow H(X|Y=1)=0$
 $H(X|Y) = P(Y=0)H(X|Y=0) + P(Y=1)H(X|Y=1) = \frac{1}{3} \cdot 1 + \frac{2}{3} \cdot 0 = \frac{1}{3}$
 $X=0 \rightarrow P(Y=0|X=0)=\frac{1}{2}, P(Y=1|X=0)=\frac{1}{2} \rightarrow H(Y|X=0)=1$
 $X=1 \rightarrow P(Y=0|X=1)=0, P(Y=1|X=1)=1 \rightarrow H(Y|X=1)=0$
 $H(Y|X) = \frac{2}{3} \cdot 1 + \frac{1}{3} \cdot 0 = \frac{2}{3}$

(c) $H(X, Y)$.
 $-\sum_{(x,y)} p(x,y) \log_2 p(x,y) = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{3}$

(d) $H(X) - H(Y | X)$.
 $\log_2 2 - \frac{2}{3} = \log_2 2 - \frac{2}{3}$

(e) $I(X; Y) = H(Y) - H(Y|X) = H(X) - H(X|Y) = H(X) + H(Y) - H(X, Y)$
 $= \log_2 2 - \frac{2}{3}$

(f) (a)부터 (e)까지 구한 양(quantity)들을 벤 다이어그램으로 나타내시오.



4-2. KL-divergence

(a) $D(p||q) = D(q||p)$ 가 성립하지 않는 반례를 제시하시오.
 $p = (0.9, 0.1), q = (0.5, 0.5)$
 $D(p||q) = 0.9 \ln \frac{0.9}{0.5} + 0.1 \ln \frac{0.1}{0.5} \neq 0$
 $D(q||p) = 0.5 \ln \frac{0.5}{0.9} + 0.5 \ln \frac{0.5}{0.1} \neq 0$

$D(q||p) \neq D(p||q)$

(b) $D(p||q) \geq 0$ 임을 보이시오. (Hint : Jensen's Inequality)

$D(p||q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = -\sum_x p(x) \log \frac{q(x)}{p(x)}$
 $r(x) = \frac{q(x)}{p(x)}, p(x) > 0$ 라 하자. $D(p||q) = -E_p[\log r(x)]$
 by Jensen's Inequality, $E_p[\log r(x)] \leq \log(E_p[r(x)])$
 $E_p[r(x)] = \sum_x p(x) \frac{q(x)}{p(x)} = \sum_x q(x) = 1$ 이라
 $E_p[\log r(x)] \leq \log 1 = 0 \rightarrow -E_p[\log r(x)] \geq 0$
 $\therefore D(p||q) \geq 0$

Reference

- Elements of Information Theory (2nd Ed.), T. M. Cover & J. A. Thomas
- Convex Optimization for ML, Prof. Changho Suh

Data Science Lab

담당자: 14 기 박창용, 어희정, 여준호

qkrckddyd0@yonsei.ac.kr

heejung.uh@gmail.com

asap03153@gmail.com