



- 본 과제는 학회 정규 세션 「Linear Algebra」, 「Basic Statistics」 및 「Math for ML」 일부 내용을 다루며, 개념의 이해와 실제 활용 사례에 대한 이해를 돋기 위해 기획되었습니다. 평가를 위한 것이 아니므로, 주어진 힌트를 적극 활용하시고 학회원 간 토론, Slack의 질의응답을 활용하여 해결해주십시오. 단, 답안 표절은 금지합니다.
- 2/11 (수) 23시 59분까지 Github에 PDF 파일 하나로 제출해주십시오. Github에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 활용해주십시오.

## 문제 1 선형대수 기초 (Linear Algebra Basic)

### 1. $Ax = b$ 의 동치 조건

$n \times n$  정사각행렬  $A$ 에 대하여 다음 조건들은 동치(equivalent)입니다.

- 행렬  $A$ 는 가역적(invertible)이다.
- 임의의  $n \times 1$  벡터  $b$ 에 대하여 방정식  $Ax = b$ 는 유일한 해를 갖는다.
- 동차 방정식(Homogeneous equation)  $Ax = 0$ 은 오직 자명한 해(trivial solution,  $x = 0$ )만을 갖는다.

#### 1-1. 다음과 같은 삼변수 함수 $f(x, y, z)$ 가 주어져 있습니다.

$$f(x, y, z) = x^2 + y^2 + 1.5z^2 + xy + yz + zx$$

- (1) 이 함수의 헤시안 행렬(Hessian Matrix)  $A$ 를 구하고 PD(Positive Definite), PSD, ND, NSD 중 무엇인지 판별하시오.

$$A = \begin{bmatrix} f_{xx} & f_{xy} & f_{xz} \\ f_{yx} & f_{yy} & f_{yz} \\ f_{zx} & f_{zy} & f_{zz} \end{bmatrix} \quad \begin{array}{l} f_{xx}=2 \\ f_{yy}=2 \\ f_{zz}=3 \end{array} \quad A = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{bmatrix}$$

1)  $M_1=2>0$   
2)  $M_2=\det\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{bmatrix}=3>0$  (PD)  
3)  $M_3=\det(A)=2(6-1)-1(3-1)+(-1)=10>0$

- (2) 위에서 구한 행렬  $A$ 의 역행렬  $A^{-1}$ 을 계산하시오.

$$A^{-1} = \frac{1}{\det(A)} \text{adj}(A) = \frac{1}{10} \begin{bmatrix} 5 & -2 & -1 \\ -2 & 5 & 1 \\ 1 & 1 & 3 \end{bmatrix}$$

- (3) 만약 특정 상수  $k$ 에 대해 함수의 항  $xy$ 가  $kxy$ 로 변하여  $\det(A) = 0$ 이 된다면, 조건 (b)는 여전히 성립하는가? 그 이유를 행렬식(determinant)과 관련지어 설명하시오.

성립하지 않음, 1번의 조건에 따르면 행렬  $A$ 가 가역적이어야 방정식  $Ax=b$ 가 유일한 해를 갖는데  $\det(A)=0$ 이면 행렬  $A$ 는 특이행렬이 되어 역행렬 존재하지 않고 따라서 유일한 해를 갖지 않으므로 조건 b는 성립하지 않음

#### 1-2. (Optional)

- (1) (a), (b), (c) 세 조건들이 동치임을 증명하시오.

- (2) 행렬  $A$ 가 가역적이라고 가정할 때, 임의의  $b$ 에 대하여  $Ax = b$ 를 만족하는 해  $x$ 가 항상 존재함을 대수적으로 유도하여 증명하고 해당 증명의 의미를 서술하시오.

## 문제 2 특이값 분해 (SVD)

특이값 분해(SVD)는 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 1) 항상 대칭 행렬을 이루는 두 행렬  $B^T B, BB^T$ 를 계산하고, 이들의 고유값을 계산해 특이값  $\sigma$ 와 고유 벡터를 통해 직교대각화하여  $B^T B = V D V^T, BB^T = U D U^T$ 를 구합니다.
- 2) 0이 아닌 특이값들을 내림차순으로 나열하여  $\Sigma$ 를 구성하고, 이들을 모두 활용해  $A = U \Sigma V^T$ 를 구합니다.

다음 행렬  $B$ 에 특이값 분해를 적용하였을 때 나오는 행렬  $U, \Sigma, V^T$ 를 각각 구하시오.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

1.  $U$  구하기 ( $BB^T$ 의 고유 벡터)

$$BB^T = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix}$$

• 고유값:  $\lambda_1=2, \lambda_2=1$

• 특이값:  $\sigma_1=\sqrt{2}, \sigma_2=1$

• 고유벡터:  $u_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, u_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$

•  $U = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$

$$\text{1) } \lambda_1=2$$

$$\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$z=0$$

$$-x+y=0 \Rightarrow x=y \\ \therefore v_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

2.  $\Sigma$  구하기 (특이값)

$$\Delta_1 = \sqrt{\lambda_1} = \sqrt{2}$$

$$\Delta_2 = \sqrt{\lambda_2} = \sqrt{1} = 1$$

$$z = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$2) \lambda_2=1$$

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$y=0 \Rightarrow v_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

$$3) \lambda_3=0$$

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \endbmatrix = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$z=0$$

$$x+y=0 \Rightarrow x=-y \\ \therefore v_3 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}$$

$$\therefore V = [v_1 \ v_2 \ v_3] = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

3.  $V$  구하기 ( $B^T B$ 의 고유벡터)

$$B^T B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad B^T = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$B^T B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$\det \begin{bmatrix} 1-\lambda & 1 & 0 \\ 0 & 1-\lambda & 0 \\ 0 & 0 & 1-\lambda \end{bmatrix} = 0$$

$$\lambda_1=2, \lambda_2=1, \lambda_3=0$$

$$V^T = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & 0 & 1 \end{bmatrix}$$

3-1) c1

임의의 두 점  $P_1 = (x_1, y_1), P_2 = (x_2, y_2)$ 가  $C_1$ 에 속한다고 가정하자. 즉  $x_1(2) + y_1(2) \leq 1$ 이고 두점의 내분점  $P_{new} = \theta P_1 + (1 - \theta)P_2$ 의 좌표는  $(\theta x_1 + (1 - \theta)x_2, \theta y_1 + (1 - \theta)y_2)$ 인데 이 점이 조건을 만족하는지 확인해보자.  $(\theta x_1 + (1 - \theta)x_2) + (\theta y_1 + (1 - \theta)y_2) = \theta(x_1 + y_1) + (1 - \theta)(x_2 + y_2)$  가정에 의해  $x+y \leq 1$ 이므로: 따라서 내분점도 부등식을 만족하므로 Convex Set이다.

c2

L1 Norm:  $\|x\|_1 = \sum |x_i|$

두 점  $u, v \in C_2$  라 하면  $\|u\|_1 \leq 1, \|v\|_1 \leq 1$   
내분점  $z = \theta u + (1 - \theta)v$ 에 대해 삼각 부등식과 노름의 성질을 적용하면  $\|\theta u + (1 - \theta)v\|_1 \leq \|\theta u\|_1 + \|(1 - \theta)v\|_1$   
 $\theta \geq 0$  이므로:  $= \theta\|u\|_1 + (1 - \theta)\|v\|_1$  가정을 대입하면:  $\leq \theta(1) + (1 - \theta)(1) = 1$  따라서 Convex Set이다.

c3

두 점  $(x_1, y_1), (x_2, y_2) \in C$  라 하면  $y_1 \geq e^{x_1}, y_2 \geq e^{x_2}$ 이다.  
내분점  $(x_{new}, y_{new}) = (\theta x_1 + (1 - \theta)x_2, \theta y_1 + (1 - \theta)y_2)$  이다.  $y_{new} = \theta y_1 + (1 - \theta)y_2 \geq \theta e^{x_1} + (1 - \theta)e^{x_2}$  식이 성립하는지 확인해보면

함수  $f(x) = e^x$  는 Convex Function이고  $f(x) = e^x > 0$  정의에 의해 다음이 성립한다.  $\theta e^{x_1} + (1 - \theta)e^{x_2} \geq e^{\theta x_1 + (1 - \theta)x_2}$   
따라서  $y_{new} \geq e^{x_{new}}$  가 성립하므로 Convex Set이다.

3-1-2)

집합  $S$ 의 두 원소  $(x_1, t_1), (x_2, t_2)$ 를 잡으면 조건에 의해  $t_1 \geq f(x_1), t_2 \geq f(x_2)$   
내분점  $(x, t) = \theta(x_1, t_1) + (1 - \theta)(x_2, t_2)$  라 할 때,  $t \geq f(x)$ 임을 보이면 된다.

$f$ 가 Convex function이므로 정의에 의해:  $\theta f(x_1) + (1 - \theta)f(x_2) \geq f(\theta x_1 + (1 - \theta)x_2) = f(x)$   
결국  $t \geq f(x)$  이 성립하므로 Epigraph  $S$ 는 Convex Set이다.

3-2-1)

a)

$h(x) = f(x) + g(x)$ 라 하자.  $h(\theta x + (1 - \theta)y) = f(\theta x + (1 - \theta)y) + g(\theta x + (1 - \theta)y)$

$$\begin{aligned} &\leq [\theta f(x) + (1 - \theta)f(y)] + [\theta g(x) + (1 - \theta)g(y)] = \theta[f(x) + g(x)] + (1 - \theta)[f(y) + g(y)] \\ &= \theta h(x) + (1 - \theta)h(y) \end{aligned}$$

b)

$h(x) = f(Ax+b)$ 라 하자.  $h(\theta x + (1 - \theta)y) = f(A(\theta x + (1 - \theta)y) + b)$

행렬 연산의 형성에 의해:  $= f(\theta(Ax + b) + (1 - \theta)(Ay + b))$

$X = Ax+b, Y = Ay+b$ 로 치환 생각하면,  $f$ 가 Convex하므로:  $\leq \theta f(Ax + b) + (1 - \theta)f(Ay + b)$

따라서  $h(x)$  Convex입니다.

### 문제 3 Convex Sets & Functions

#### 3-1. Convex Set

1. 다음 집합들이 Convex set인지 증명하시오.

$$C_1 = \{(x, y) \in \mathbb{R}^2 : x + y \leq 1\}$$

$$C_2 = \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\}$$

$$C_3 = \{(x, y) \in \mathbb{R}^2 : y \geq e^x\}$$

2. 함수  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 가 convex function일 때,  $f$ 의 epigraph인 집합  $S$ 가 convex set임을 보이시오.

$$S = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} : t \geq f(x)\}$$

#### 3-2. Convex Function

1. Convex 함수의 합성

$f : \mathbf{R}^d \rightarrow \mathbf{R}$ 가 실수 값을 갖는 함수라고 합시다.

(a) 함수  $f(x)$ 와  $g(x)$ 가 convex일 때,  $f(x) + g(x)$  또한 convex임을 보이시오.

(b)  $A$ 와  $b$ 가 호환되는 크기의 행렬과 벡터라고 합시다.  $f(x)$ 가 convex라면  $f(Ax + b)$  또한 convex임을 보이시오.

2. Convex Optimization

또 다른 함수  $f : \mathbf{R}^d \rightarrow \mathbf{R}$ 를 고려해 봅시다.

$$f(x) = \|Ax - b\|^2.$$

오직 convex 함수의 정의만을 사용하여,  $f(x)$ 가  $x \in \mathbf{R}^d$ 에서 convex임을 보이시오.

## 문제 4 정보이론 (Information Theory)

### 4-1. Entropy

확률분포  $p(x, y)$  가 다음과 같이 주어졌다고 합시다.

$X \setminus Y$	0	1
0	$\frac{1}{3}$	$\frac{1}{3}$
1	0	$\frac{1}{3}$

다음 값들을 구하시오.

$$\begin{aligned} P(X=0, Y=0) &= 1/3, P(X=0, Y=1) = 1/3, P(X=1, Y=0) = 0, P(X=1, Y=1) = 1/3 \\ P(X=0) &= 2/3, P(X=1) = 1/3, P(Y=0) = 1/3, P(Y=1) = 2/3 \end{aligned}$$

$$(a) H(X), H(Y). H(X) = -\sum p(x) \log_2 p(x) \quad H(X) = -\left(\frac{2}{3} \log_2 \frac{2}{3} + \frac{1}{3} \log_2 \frac{1}{3}\right) = H(Y)$$

$$(b) H(X | Y), H(Y | X). H(X|Y) = H(X, Y) - H(Y) = \log_2 3 - \left(\log_2 3 - \frac{2}{3}\right) = \frac{2}{3} \approx 0.667 \text{ bits} \\ H(Y|X) = H(X, Y) - H(X) = \log_2 3 - \left(\log_2 3 - \frac{2}{3}\right) = \frac{2}{3} \approx 0.667 \text{ bits}$$

$$(c) H(X, Y). H(X, Y) = -\sum \sum p(x, y) \log_2 p(x, y) \quad H(X, Y) = -3 \times \left(\frac{1}{3} \log_2 \frac{1}{3}\right) = \log_2 3$$

$$(d) H(Y) - H(Y | X). H(Y) - H(Y|X) = \left(\log_2 3 - \frac{2}{3}\right) - \frac{2}{3} = \log_2 3 - \frac{4}{3} \approx 1.585 - 1.333 = \mathbf{0.252} \text{ bits}$$

$$(e) I(X; Y). I(X; Y) = H(X) + H(Y) - H(X, Y)$$

$$I(X; Y) = \left(\log_2 3 - \frac{2}{3}\right) + \left(\log_2 3 - \frac{2}{3}\right) - \log_2 3 = 2 \log_2 3 - \frac{4}{3} - \log_2 3 = \log_2 3 - \frac{4}{3} \approx \mathbf{0.252} \text{ bits}$$

(f) (a)부터 (e)까지 구한 양(quantity)들을 벤 다이어그램으로 나타내시오.

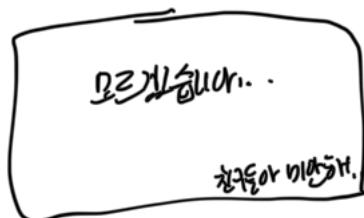


### 4-2. KL-divergence

(a)  $D(q||p) = D(p||q)$  가 성립하지 않는 반례를 제시하시오.

$$p(x) = [0.5, 0.5] \quad D(p||q) = \sum p(x) \log \frac{p(x)}{q(x)} = 0.5 \log 5 + 0.5 \log \frac{5}{9} \approx 0.511 \quad \cancel{\text{X}}$$

$$(b) D(p||q) \geq 0 \text{임을 보이시오. (Hint : Jensen's Inequality)} \quad D(q||p) = \sum q(x) \log \frac{q(x)}{p(x)} = 0.1 \log \frac{1}{5} + 0.9 \log 1.8 \approx 0.368$$



$\therefore D(p||q) \neq D(q||p)$

## Reference

- Elements of Information Theory (2nd Ed.), T. M. Cover & J. A. Thomas
- Convex Optimization for ML, Prof. Changho Suh

## Data Science Lab

담당자: 14 기 박창용, 어희정, 여준호

qkrckddyd0@yonsei.ac.kr

heejung.uh@gmail.com

asap03153@gmail.com