



- 본 과제는 학회 정규 세션 「Linear Algebra」, 「Basic Statistics」 및 「Math for ML」 일부 내용을 다루며, 개념의 이해와 실제 활용 사례에 대한 이해를 돋기 위해 기획되었습니다. 평가를 위한 것이 아니므로, 주어진 힌트를 적극 활용하시고 학회원 간 토론, Slack의 질의응답을 활용하여 해결해주십시오. 단, 답안 표절은 금지합니다.
- 2/11 (수) 23시 59분까지 Github 에 PDF 파일 하나로 제출해주십시오. Github에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 활용해주십시오.

문제 1 선형대수 기초 (Linear Algebra Basic)

1. $Ax = b$ 의 동치 조건

$n \times n$ 정사각행렬 A 에 대하여 다음 조건들은 동치(equivalent)입니다.

- 행렬 A 는 가역적(invertible)이다.
- 임의의 $n \times 1$ 벡터 b 에 대하여 방정식 $Ax = b$ 는 유일한 해를 갖는다.
- 동차 방정식(Homogeneous equation) $Ax = 0$ 은 오직 자명한 해(trivial solution, $x = 0$)만을 갖는다.

1-1. 다음과 같은 삼변수 함수 $f(x, y, z)$ 가 주어져 있습니다.

$$f(x, y, z) = x^2 + y^2 + 1.5z^2 + xy + yz + zx$$

- (1) 이 함수의 헤시안 행렬(Hessian Matrix) A 를 구하고 PD(Positive Definite), PSD, ND, NSD 중 무엇인지 판별하시오.

$$\begin{matrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{matrix} \quad D_1 = 2 > 0, D_2 = 3 > 0, D_3 = 10 - 2 - 1 = 7 > 0 \quad \therefore \text{PD}$$

- (2) 위에서 구한 행렬 A 의 역행렬 A^{-1} 을 계산하시오.

$$\frac{1}{7} \begin{pmatrix} 5 & -2 & -1 \\ -2 & 5 & -1 \\ -1 & -1 & 3 \end{pmatrix}$$

- (3) 만약 특정 상수 k 에 대해 함수의 항 xy 가 kxy 로 변하여 $\det(A) = 0$ 이 된다면, 조건 (b)는 여전히 성립하는가? 그 이유를 행렬식(determinant)과 관련지어 설명하시오.

no because A^{-1} doesn't exist

1-2. (Optional)

- (1) (a), (b), (c) 세 조건들이 동치임을 증명하시오.

- (2) 행렬 A 가 가역적이라고 가정할 때, 임의의 b 에 대하여 $Ax = b$ 를 만족하는 해 x 가 항상 존재함을 대수적으로 유도하여 증명하고 해당 증명의 의미를 서술하시오.

$$x = A^{-1}b$$

문제 2 특이값 분해 (SVD)

특이값 분해(SVD)는 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 1) 항상 대칭 행렬을 이루는 두 행렬 $B^T B, BB^T$ 를 계산하고, 이들의 고유값을 계산해 특이값 σ 와 고유 벡터를 통해 직교대각화하여 $B^T B = V D V^T, BB^T = U D U^T$ 를 구합니다.
- 2) 0이 아닌 특이값들을 내림차순으로 나열하여 Σ 를 구성하고, 이들을 모두 활용해 $A = U \Sigma V^T$ 를 구합니다.

다음 행렬 B 에 특이값 분해를 적용하였을 때 나오는 행렬 U, Σ, V^T 를 각각 구하시오.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$B^T B = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix} \quad \sigma_1 = \sqrt{2}, \quad \sigma_2 = 1$$

$$V = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$\Sigma = \begin{pmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$

$$v_i = \frac{1}{\sigma_i} B^T u_i$$

$$v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$$

$$v_2 = \frac{1}{1} \quad " \quad \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$$

$$v_3 \perp v_1, v_2 \rightarrow v_3 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$V^T = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \end{pmatrix}$$

문제 3 Convex Sets & Functions

3-1. Convex Set

1. 다음 집합들이 Convex set인지 증명하시오.

$$\begin{aligned} C_1 &= \lambda(x_u + y_u) + (1-\lambda)(x_v + y_v) \\ &\leq \lambda(1) + (1-\lambda)(1) = 1 \end{aligned}$$

$$\begin{aligned} C_2 &\triangleq \text{ineqwl'ty} \\ \|(\lambda u + (1-\lambda)v)\|_1 &\leq \lambda\|u\|_1 + (1-\lambda)\|v\|_1 \\ &\leq \lambda(1) + (1-\lambda)(1) = 1 \end{aligned}$$

$$C_1 = \{(x, y) \in \mathbb{R}^2 : x + y \leq 1\}$$

$$\begin{aligned} C_2 &= \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\} \\ C_3 &= \{(x, y) \in \mathbb{R}^2 : y \geq e^x\} \end{aligned}$$

$$y' = \lambda y_1 + (1-\lambda)y_2 \geq \lambda e^{x_1} + (1-\lambda)e^{x_2} \geq e^{\lambda x_1 + (1-\lambda)x_2}$$

2. 함수 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 가 convex function일 때, f 의 epigraph인 집합 S 가 convex set임을 보이시오.

$$\begin{aligned} S &= \{(x, t) \in \mathbb{R}^n \times \mathbb{R} : t \geq f(x)\} \quad (x_1, t_1), (x_2, t_2) \in S \\ (x', t') &= \lambda x_1 + (1-\lambda)x_2 \geq \lambda f(x_1) + (1-\lambda)f(x_2) \\ &\geq f(\lambda x_1 + (1-\lambda)x_2) = f(x') \end{aligned}$$

\uparrow
 $f \text{ convex}$

3-2. Convex Function

1. Convex 함수의 합성

$f : \mathbb{R}^d \rightarrow \mathbb{R}$ 가 실수 값을 갖는 함수라고 합시다.

(a) 함수 $f(x)$ 와 $g(x)$ 가 convex일 때, $f(x) + g(x)$ 또한 convex임을 보이시오.

$$\lambda(f+g)(x) + (1-\lambda)(f+g)(y)$$

$$(f+g)(\lambda x + (1-\lambda)y) = f(\lambda x + (1-\lambda)y) + g(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y) + \lambda g(x) + (1-\lambda)g(y)$$

(b) A 와 b 가 호환되는 크기의 행렬과 벡터라고 합시다. $f(x)$ 가 convex라면 $f(Ax + b)$ 또한 convex임을 보이시오.

$$= h(x)$$

$$h(\lambda x + (1-\lambda)y) = f(\lambda(Ax + b) + (1-\lambda)(Ay + b)) \leq \lambda f(Ax + b) + (1-\lambda)f(Ay + b)$$

\uparrow
 $f \text{ convex}$

$$= \lambda h(x) + (1-\lambda)h(y)$$

2. Convex Optimization

또 다른 함수 $f : \mathbb{R}^d \rightarrow \mathbb{R}$ 를 고려해 봅시다.

$$f(x) = \|Ax - b\|^2.$$

오직 convex 함수의 정의만을 사용하여, $f(x)$ 가 $x \in \mathbb{R}^d$ 에서 convex임을 보이시오.

$$u = Ax - b, v = Ay - b$$

$$\|\lambda u + (1-\lambda)v\|^2 \leq \lambda\|u\|^2 + (1-\lambda)\|v\|^2$$

$$\begin{aligned} \text{LHS} - \text{RHS} &= \lambda(1-\lambda)(\|u\|^2 + \lambda(1-\lambda)\|v\|^2 - 2\lambda(1-\lambda)\langle u, v \rangle) \\ &= \lambda(1-\lambda)\|(u-v)\|^2 \\ &\geq 0 \end{aligned}$$

문제 4 정보이론 (Information Theory)

4-1. Entropy

확률분포 $p(x, y)$ 가 다음과 같이 주어졌다고 합시다.

$X \setminus Y$	0	1
0	$\frac{1}{3}$	$\frac{1}{3}$
1	0	$\frac{1}{3}$

다음 값들을 구하시오.

$$(a) H(X) = H(Y) = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} = \log_2 3 - \frac{2}{3}$$

$$(b) H(X | Y), H(Y | X). \quad H(X|Y) = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 1 = \frac{2}{3}, \quad H(Y|X) = \frac{2}{3} \cdot 1 + \frac{1}{3} \cdot 0 = \frac{2}{3}$$

$$(c) H(X, Y) = -3 \cdot \frac{1}{3} \log_2 \frac{1}{3} = \log_2 3$$

$$(d) H(Y) - H(Y | X) = \log_2 3 - \frac{4}{3}$$

answ: $H(X, Y)$

$$(e) I(X; Y) = H(Y) - H(Y|X) = \log_2 3 - \frac{4}{3}$$

(f) (a)부터 (e)까지 구한 양(quantity)들을 벤 다이어그램으로 나타내시오.



4-2. KL-divergence

$$(a) D(q||p) = D(p||q) 가 성립하지 않는 반례를 제시하시오. \quad p = [0.5, 0.5], q = [0.25, 0.75]$$

$$.5 \log_2 2 + .5 \log_2 \frac{2}{3} \neq .25 \log_2 .5 + .75 \log_2 1.5$$

(b) $D(p||q) \geq 0$ 임을 보이시오. (Hint : Jensen's Inequality)

$$\begin{aligned} &= \sum p(x) \log \frac{q(x)}{p(x)} = -\sum p(x) \log \frac{q(x)}{p(x)} = -\sum p(x) \left[\log \frac{q(x)}{p(x)} \right] \geq -\log \left(\sum p(x) \frac{q(x)}{p(x)} \right) \\ &= -\log \left(\sum p(x) q(x) \right) \\ &= -\log (E_p(q(x))) \\ &= -\log 1 = 0 \end{aligned}$$

Reference

- Elements of Information Theory (2nd Ed.), T. M. Cover & J. A. Thomas
- Convex Optimization for ML, Prof. Changho Suh

Data Science Lab

담당자: 14 기 박창용, 어희정, 여준호

qkrckddyd0@yonsei.ac.kr

heejung.uh@gmail.com

asap03153@gmail.com